

Máquinas de soporte vectorial para la predicción de series temporales financieras en modelos clásicos y cuánticos

Leynder Elian Sánchez Ortega¹

¹ Universidad de Especialidades Espíritu Santo, Samborondón, Ecuador
leynder.sanchez@uees.edu.ec

Abstract. The abstract should summarize the contents of the paper in short terms, i.e. 150-250 words.

Keywords: First Keyword, Second Keyword, Third Keyword.

1 Introducción

La predicción de series temporales financieras (FTS) es un elemento clave en la gestión de riesgos y toma de decisiones económicas [1] dado que permite anticipar tendencias y reducir la incertidumbre en los mercados financieros [2]. El comportamiento de dichos mercados es afectado por una serie de factores macro y microeconómicos, que incluyen sucesos geopolíticos, la situación económica en general y las expectativas de los inversores [2]. Aunque la Hipótesis del Mercado Eficiente (HME) afirma que los precios de los activos reflejan instantáneamente toda la información disponible, sugiriendo que los datos históricos de precios y volúmenes carecen de poder predictivo [3], la evidencia muestra la existencia de fricciones, no linealidades y dependencias temporales. Estas particularidades, sumadas a la volatilidad y complejidad de los mercados accionarios [1], justifican la importancia de la investigación continua de modelos que permitan capturar patrones complejos y así mismo tener una visión panorámica para mejores decisiones financieras y de inversión [4].

El pronóstico de mercado de valores cuenta con una variedad de modelos estadísticos y de aprendizaje automático (ML) para predecir fluctuaciones futuras [5]. El análisis del mercado bursátil ha tenido cambios significativos con el desarrollo de herramientas, métodos de la inteligencia artificial y el análisis del Big Data. Los enfoques basados en ML se han vuelto relevantes durante la última década con la finalidad de superar las restricciones de los modelos estadísticos tradicionales, que en muchas ocasiones asumen linealidad y estacionariedad de los datos [2] [6]. Los modelos de ML aprenden directamente de los datos lo que les permite modelar relaciones complejas, no lineales, y extraer información oculta de una gran cantidad de conjuntos de datos bursátiles [2] [7]. Dentro de este marco, los algoritmos de aprendizaje supervisado sobresalen por su eficacia en tareas de clasificación y de regresión financiera [7].

En contraste de otros métodos de inteligencia artificial, como las redes neuronales tradicionales (ANN), que pueden degradar su desempeño frente al ruido propio de los mercados financieros, estos algoritmos ofrecen una mejora en la generalización y resistencia al overfitting y mantienen un rendimiento más estable incluso en contextos de alta volatilidad [8] [9].

Entre los métodos basados en aprendizaje supervisado, las máquinas de soporte vectorial (SVM) se han posicionado como una de las herramientas más estables en tareas de predicción financiera por su simplicidad, alta precisión y menores requerimientos computacionales [10]. Su funcionamiento se basa en el principio de Minimización de Riesgo Estructural (SRM). A diferencia de métodos que pretenden disminuir el error empírico como las redes neuronales, el propósito central de una SVM es encontrar un hiperplano óptimo que maximice el margen de separación entre las clases de datos o minimice el error dentro de un margen específico en tareas de regresión (SVR) [9] [11] [12]. Las SVM utilizan funciones kernel que facilitan la proyección de datos financieros no lineales a un espacio de características de mayor dimensión, lo que permite identificar patrones y tendencias que no se observan directamente en el espacio original [13].

Sin embargo, el procesamiento de espacios de características de alta dimensión para modelar series financieras complejas requiere un costo computacional que puede limitar la eficacia de los métodos clásicos [10] [14]. En este contexto, la computación cuántica introduce una alternativa mediante el uso de qubits. Mientras los bits clásicos solo pueden adoptar estados binarios, los qubits aprovechan principios de la mecánica cuántica, como la superposición y el entrelazamiento, para realizar múltiples cálculos simultáneos, mejorando los algoritmos de aprendizaje automático y procesando la información de una manera fundamentalmente distinta a los enfoques clásicos [14] [15] [16]. Diferentes investigaciones sitúan al sector financiero como uno de los principales campos en beneficiarse de esta adopción, con aplicaciones potenciales desde la optimización de portafolios y el análisis de riesgo crediticio hasta la predicción de crisis de mercado [6] [17] [18].

Las Máquinas de Soporte Vectorial Cuánticas (QSVM) implementan esta mejora al reemplazar el kernel clásico por un kernel cuántico evaluado directamente en este tipo de hardware [19]. Mediante mapas de características, los datos financieros se proyectan en un espacio de Hilbert con una mayor dimensionalidad. Esto otorga a las QSVM la capacidad de identificar correlaciones no lineales complejas, que puede traducirse en un desempeño predictivo más preciso y eficiente [10] [18].

La toma de decisiones financieras involucran un riesgo intrínseco, por lo que es necesario aprovechar estrategias de inversión en un sustento técnico y no meramente subjetivo [1]. A pesar del potencial disruptivo de estos modelos cuánticos, la literatura se ha centrado primordialmente en el pronóstico de mercado de valores internacionales.

les altamente líquidos y estructurados, donde la disponibilidad y accesibilidad de los datos estandarizados (OHCLV¹) es abundante.

No obstante, la validación de estas ventajas teóricas en mercados emergentes sigue siendo escasa y presenta desafíos. En el mercado bursátil ecuatoriano, particularmente en la Bolsa de Valores de Guayaquil (BVG), se observan condiciones típicas de mercados de menor escala, y la negociación se caracteriza por tener una menor liquidez, volúmenes de transacciones con irregularidad temporal, y una estructura de información que no es eficiente en contraste a mercados consolidados [4] [20].

La combinación de la realidad del mercado bursátil ecuatoriano, junto con las limitaciones del hardware cuántico actual (NISQ²), que presentan cierta perceptibilidad al ruido [17], resulta pertinente la necesidad de analizar si las ventajas de complejidad y generalización atribuidas para las QSVM se mantienen el aplicarse bajo estas condiciones.

Existe una relación directa entre una bolsa de valores consolidada y el crecimiento económico de los países, países como Estados Unidos y Alemania muestran el ejemplo de cómo una bolsa de valores ampliamente desarrollada funciona como un motor financiero [20]. Por otro lado, el mercado bursátil ecuatoriano enfrenta un crecimiento limitado debido a una baja liquidez, volúmenes de negociación irregulares y una escasa participación de la ciudadanía, factores que se los asocian a una reducida cultura bursátil y a la falta de herramientas que potencien el desarrollo [4] [20]. Estos factores afectan a la competitividad con mercados internacionales, provocando que inversores ecuatorianos perciban el entorno local como ineficiente [4]. Por ende, es importante fomentar investigaciones que no solo visibilicen la importancia de la Bolsa de Valores de Guayaquil (BVG) como una herramienta de reactivación económica, sino que también se propongan herramientas tecnológicas que impulsen la participación en el área del análisis y predicción financiera.

La computación cuántica se ha posicionado como un área investigativa con la capacidad para solventar problemas de optimización y ML caracterizados por una alta dimensionalidad y complejidad computacional. Estudios coinciden en que el sector financiero estará entre las primeras industrias en sacarle provecho a la “ventaja cuántica”, siendo un ambiente idóneo para evaluar estas técnicas dada la naturaleza intensiva de los datos y presencia de relaciones no lineales en los mercados [6] [15] [17]. Los modelos de QML³ proporcionan procesos alternativos de cálculo y representación que podrían mejorar la escalabilidad y generalización frente a enfoques clásicos en ciertas condiciones.

¹ OHCLV: Open – High – Low – Close – Volume.

² NISQ: Noisy Intermediate-Scale Quantum

³ QML: Quantum Machine Learning

Por tanto, se vuelve necesario evaluar la aplicabilidad de la QSVM en el pronóstico de precios de acciones de empresas que cotizan en la Bolsa de Valores de Guayaquil, considerando a emisores representativos como Corporación Favorita y Banco de Guayaquil, entidades que mantienen un alto volumen de negociación y, en el caso de Corporación Favorita que se ha mantenido de manera regular en las cotizaciones brindando estabilidad a colaboradores, generando utilidades a los accionistas y aportando al desarrollo económico del país [21].

El presente estudio tiene como objetivo general establecer bases metodológicas para el análisis bursátil ecuatoriano con modelos SVM y QSVM aplicados a acciones de alta liquidez, que cotizan en la Bolsa de Valores de Guayaquil. Para alcanzar este propósito, el desarrollo de la investigación se guía por dos objetivos específicos. En primer lugar, se desarrollan modelos de regresión basados en máquinas de soporte vectorial clásicas y cuánticas utilizando datos históricos del mercado accionario ecuatoriano. Posteriormente, se evalúa el comportamiento y la precisión de cada enfoque, tanto clásico como cuántico, frente a la volatilidad de los datos locales.

2 Marco Teórico

2.1 Conceptos fundamentales

Series temporales financieras (FTS).

Constituyen la representación de secuencias cronológicas de observaciones asociadas a variables económicas, como los precios históricos o los volúmenes de negociación de activos bursátiles. Estas series se caracterizan por una alta volatilidad, ruido y por presentar interdependencias no lineales que complican su modelado predictivo mediante métodos estadísticos tradicionales [22] [23]. Su comportamiento es el resultado de la influencia simultánea de factores macroeconómicos, sucesos geopolíticos, expectativas de los inversores y políticas operativas de entidades comerciales [2].

Máquinas de soporte vectorial clásicas (SVM y SVC).

Algoritmos de ML supervisados ampliamente utilizados en el modelado financiero por su capacidad para operar en espacios de alta dimensionalidad [7]. Su fundamento matemático se centra en el principio SRM, que busca encontrar un equilibrio entre la reducción del error en los datos de entrenamiento y la capacidad de generalización del modelo, mitigando el sobreajuste [8] [24].

En pronósticos de dirección del mercado, se emplea la clasificación de vectores de soporte SVC, que tiene como objetivo encontrar un hiperplano óptimo que separe las distintas clases de datos maximizando el ancho del margen o frontera de decisión entre ellas, logrando clasificaciones más robustas frente al ruido y la volatilidad. Para proyectar los datos a un espacio de mayor dimensionalidad, las SVM incorporan funciones kernel que utilizan funciones matemáticas para alcanzar esta característica (espacio de Hilbert, $\mathcal{H}$) donde la separación lineal de las clases resulta viable. Utilizando comúnmente kernels lineales, polinomiales o gaussianos (RBF) [5] [8].

Fundamentos de computación cuántica.

Un paradigma tecnológico impulsado por los principios de la mecánica cuántica, con la capacidad de habilitar espacios computacionales exponencialmente mayores que los de la computación clásica [25]. La convergencia de fenómenos como la superposición, en donde un qubit puede existir en diferentes estados simultáneamente, el entrelazamiento, que vincula los estados de varios qubits, y la interferencia que modula constructiva o destructivamente las amplitudes de probabilidad, da lugar al paralelismo cuántico y una mayor capacidad de representación en espacios de Hilbert de alta dimensionalidad [25] [26].

Máquinas de soporte vectorial cuántico (QSVM).

Amplían el marco de los modelos clásicos de SVM incorporando los fundamentos de la computación cuántica. La diferencia central radica en el reemplazo del kernel tradicional por uno cuántico. Para ello, las QSVM emplean un mapa de características (quantum feature map) que codifica datos clásicos en estados de qubits. Mediante este proceso, los datos se representan en un espacio de Hilbert de dimensionalidad expo-

nencial, permitiendo la captura de relaciones altamente no lineales entre los datos [26] [27].

Métricas de evaluación.

En problemas de clasificación, la evaluación del desempeño se basa en la capacidad del modelo para categorizar correctamente la dirección del mercado (alza o baja) sobre una muestra de η observaciones. En el pronóstico de series temporales, este tipo de predicción corresponde a la clasificación binaria de tendencias, cuya calidad se evalúa aplicando métricas estadísticas con distintas propiedades analíticas [28].

Entre las más utilizadas se encuentran: la exactitud (accuracy) representa la proporción de predicciones correctas sobre el total de observaciones como indicador global del desempeño. La precisión evalúa la confiabilidad de las señales de compra, al penalizar los falsos positivos o pronósticos alcistas erróneos [3]. Por su parte, la sensibilidad (recall) cuantifica la capacidad de detección de los movimientos alcistas reales, y la puntuación F1 (F1-Score) combina ambas métricas en una media armónica permitiendo tener una medida equilibrada frente a datos desbalanceados.

2.2 Estudios relacionados

Las distintas aplicaciones de algoritmos de aprendizaje automático para el pronóstico financiero se diferencian principalmente en los enfoques de preprocesamiento, el tipo de kernel seleccionado en las SVM, y las métricas de evaluación de los modelos.

En el modelado de series temporales financieras (FTS), la estabilidad de las arquitecturas basadas en vectores de soporte ha sido validada frente a otros métodos de inteligencia artificial. [29] compararon el rendimiento de la regresión (SVR) frente a redes LSTM⁴ en la predicción de precios accionarios. En su metodología utilizaron una técnica de ventana deslizante de 60 días y la normalización MinMaxScaler. Al contrastar los resultados de los modelos mediante métricas de error absoluto, se demostró que esta arquitectura logra mayor precisión a corto plazo y que ambos enfoques evidencian una óptima capacidad de generalización en datos de pruebas sin signos de sobreajuste.

En [24] se evaluó también esta arquitectura implementando algoritmos de SVR para la predicción de precios de cierre en la Bolsa de Valores de Dhaka. Dentro de su metodología integró varios operadores de ventaneo como técnica de selección de entrada para procesar la asimetría de estos datos, evaluando el desempeño de los modelos “Win-SVR” al comparar los resultados predichos con los valores reales del mercado. De manera similar, investigaciones recientes [7], mantienen esta línea comparativa, y demuestran la capacidad de la SVM para operar en dimensionalidades complejas, en dónde la evaluación frente a modelos de Random Forest y BPNN⁵ dic-

⁴ Long Short-Term Memory

⁵ Backpropagation Neural Network

taminó que las SVM muestran un excelente rendimiento tanto en clasificación y regresión en espacios de alta dimensión, ratificando la estabilidad de la clasificación de vectores de soporte (SVC) para separar datos ruidosos.

Con el creciente interés por el desarrollo técnico de la computación cuántica en el sector financiero [30], las investigaciones comenzaron a probar algoritmos híbridos proyectados para operar bajo las restricciones de la era NISQ. Un estudio llevó a cabo una comparativa entre una QSVM y una SVM clásica para enfrentar un problema de clasificación de detección de abandono o “churn” utilizando un conjunto de datos bancarios [16]. Los investigadores definieron un kernel de incrustación cuántica optimizado, enfatizando la ventaja fundamental del hardware al evidenciar que los espacios vectoriales cuánticos son inherentemente de alta dimensión, debido a que un sistema con n qubits puede representar 2^n estados. Desde el punto de vista metodológico, la gran parte de estas aplicaciones cuánticas iniciales se estructuraron como problemas de clasificación direccional. [5] desarrollaron un modelo QFSVM⁶ para pronosticar tendencias, su experimento busco aprovechar propiedades cuánticas como la superposición y el entrelazamiento para aislar el ruido del mercado y trazar mejores fronteras de decisión. Del mismo modo, otros estudios orientados al mercado de valores han efectuado sus experimentos directamente en entornos físicos, como el IBM Quantum Experience, para estimar la tendencia direccional de índices bursátiles empleando hardware cuántico real [31].

La implementación de estudios metodológicos recientes evalúa simultáneamente el rendimiento de estos algoritmos en tareas de regresión y clasificación. [19] examinaron modelos de clasificación (QSVC) y regresión (QSVR) frente a sus contrapartes clásicas, utilizando tanto simuladores de circuitos cuánticos con inyección de ruido como un procesador cuántico con iones atrapados (IonQ Harmony). En las tareas de clasificación se utilizó un conjunto de datos de transacciones de tarjetas de crédito fraudulentas; la QSVC alcanzó un nivel de Accuracy del 70%, un desempeño comparable al de la SVM clásica, sin evidenciar diferencias significativas atribuibles al ruido del hardware. En la tarea de regresión se utilizó un conjunto de datos financieros donde la SVR clásica obtuvo una ligera superioridad. Los resultados demostraron que era necesario aplicar una técnica de aproximación de bajo rango sobre el kernel cuántico ruidoso y de optimización de hiperparámetros, para preservar el rendimiento en el hardware físico.

En un estudio de benchmarking [3] analizaron el desempeño del enfoque cuántico frente al clásico (parametrizado con kernels lineal, polinomial, y RBF⁷) y modelos estadísticos (GARCH⁸) para predecir la volatilidad de cuatro acciones con alta liquidez, entre ellas el S&P 500 y AAPL. En las pruebas se mapearon los datos utilizando una técnica de codificación de ángulo en circuitos de 10 qubits. La comparación de

⁶ Quantum Fuzzy Support Vector Machine

⁷ Radial Basis Function

⁸ Generalized AutoRegressive Conditional Heteroskedasticity

las métricas (MSE, MAE, QLIKE⁹ y Exactitud Direccional), demostró que, si bien el modelo clásico con kernel RBF logró el menor MSE, el algoritmo cuántico destacó notablemente sobre los modelos lineales y polinomiales al lograr una exactitud direccional del 60%. Con este resultado se concluyó que el modelo cuántico cuenta con una expresividad superior para identificar correctamente la dirección de los cambios de varianza, los resultados de error fueron sometidos a diferentes pruebas de significancia de Diebold-Mariano.

El análisis de la literatura pone de manifiesto que los avances en las implementaciones híbridas se han probado predominantemente en la predicción de métricas de volatilidad mediante regresión en mercados internacionales que poseen una gran cantidad de volúmenes de liquidez [3] [19], o en problemas binarios de clasificación para tendencias bancarias o bursátiles [16] [18] [26] [31]. En consecuencia, se expone un vacío metodológico sobre la capacidad de los kernels clásicos y cuánticos para clasificar series temporales al alza o a la baja en mercados emergentes como lo es la Bolsa de Valores de Guayaquil.

⁹ Quasi-Likelihood Loss

3 Metodología

El siguiente estudio se desarrolló bajo un enfoque cuantitativo basado en variables históricas del mercado bursátil y métricas estadísticas estandarizadas para la evaluación del rendimiento de los modelos. El alcance fue descriptivo, dado que se describieron detalladamente los parámetros de las características financieras, la arquitectura de los kernels clásicos y cuánticos, y el comportamiento predictivo de cada implementación frente a la volatilidad de los datos. Metodológicamente, el estudio se dividió en cinco fases: Preparación y Preprocesamiento, Ingeniería de Características, Modelado Clásico y Selección, Implementación Cuántica Comparativa, y Validación Experimental (ver Fig. 1). La preparación y preprocesamiento consistió en la ingesta, limpieza estructural y validación de la integridad temporal de los datos provistos por la Bolsa de Valores de Guayaquil (BVG). La ingeniería de características incluyó el análisis exploratorio de datos (EDA) en distintos horizontes temporales y la construcción de variables predictivas. En el modelado clásico y selección, se entrenaron y optimizaron modelos SVC tradicionales, evaluando su desempeño para determinar el horizonte temporal óptimo y la configuración de hiperparámetros más adecuada. La implementación cuántica comparativa comprendió la adaptación de las características y el desarrollo del modelo QSVC para contrastar estadísticamente su desempeño frente al enfoque clásico. Finalmente, la validación experimental consistió en el despliegue de los modelos con mejor desempeño clásico y cuántico en un aplicativo web, con el fin de registrar y auditar predicciones fuera de muestra en tiempo real.




Fig. 1. Diagrama del diseño metodológico de la investigación estructurado en cinco fases.

3.1 Contexto y selección de muestra

Como fuente principal de información, se emplearon los registros históricos oficiales emitidos por la Bolsa de Valores de Guayaquil (BVG). Los datos se extrajeron del reporte consolidado de acciones que la entidad actualiza y publica de manera diaria en un formato tabular. El análisis se realizó sobre los datos comprendidos entre el 2 de enero de 2019 y el 25 de marzo de 2026, capturando distintas condiciones de mercado durante ese intervalo. Del conjunto de empresas que cotizan en el mercado ecuatoriano, se seleccionaron las acciones de “Corporación Favorita S.A.” y “Banco de Guayaquil S.A.”, al ser los emisores que presentaban la mayor frecuencia de transacciones registradas.

Para la construcción del conjunto de datos final, el preprocesamiento consistió en el filtrado por emisor, la tipificación de las variables de precio y fecha, y el ordenamiento cronológico de las transacciones. En cuanto a la integridad temporal, se optó por conservar únicamente los intervalos reales de negociación, conservando los días sin actividad (gaps). Por ello, se descartó el uso de técnicas de imputación como el forward filling, para evitar el aumento artificial de la muestra y distorsiones estadísticas en el cálculo de retornos financieros.

A partir de la muestra temporal depurada, se realizó la ingeniería de características. Se construyeron variables predictivas de corto plazo y momentum, medidas de volatilidad (ej. volatilidad a 5 y 10 días), indicadores técnicos de tendencia (RSI y medias móviles) y variables de microestructura, como el volumen en escala logarítmica. Todas las características se construyeron con un desplazamiento temporal de $(t - 1)$ para prevenir filtración de información futura (data leakage), lo que permitió etiquetar adecuadamente la dirección del precio de cierre en los horizontes evaluados ($h = 1, 5, 20$).

3.2 Entorno de experimentación y modelado

La implementación se realizó en Python, utilizando el entorno interactivo Jupyter Notebook. Para la manipulación de datos y el análisis exploratorio se emplearon las librerías Pandas, Numpy y Statsmodels, mientras que la visualización de series temporales y resultados se generó mediante Matplotlib y Seaborn. En la fase de modelado clásico se utilizó la librería Scikit-Learn, organizando el proceso en un flujo de trabajo (Pipeline) que integró un escalado robusto de las características (RobustScaler) para moderar el impacto de valores atípicos, seguido del algoritmo de Clasificación de Vectores de Soporte (SVC). La optimización de hiperparámetros se realizó mediante una búsqueda en cuadrícula (GridSearchCV) acoplada a una validación cruzada temporal (TimeSeriesSplit). Posteriormente, la evaluación del modelo se ejecutó bajo un enfoque de validación Walk-Forward Expanding, permitiendo simular el comportamiento del modelo en escenarios de datos continuos en el tiempo. El espacio de búsqueda definido para los kernels lineal, de base radial (RBF) y polinomial se detallan en la siguiente Tabla 1.

Tabla 1. Espacio de búsqueda de hiperparámetros para modelos SVC

Kernel	Hiperparámetros	Rango de valores
Lineal	Penalización (C)	[0.1, 1, 10, 50]
	Peso de clases	[None, 'balanced']
	Penalización (C)	[0.1, 1, 10, 50]
RBF	Coficiente	['scale', 0.01, 0.1, 1]
	Peso de clases	[None, 'balanced']
	Penalización	[0.1, 1, 10]
	Grado del polinomio	[2, 3]
Polinomial	Coficiente	['scale', 0.1]
	Término indep.	[0.0, 0.5]
	Peso de clases	[None, 'balanced']

Referencias

1. Mora Rodríguez, S.P.: Predicción de precios de acciones de empresas que cotizan en la Bolsa de Valores de Guayaquil usando series de tiempo Multivariantes, <http://dspace.ups.edu.ec/handle/123456789/19812>, (2021).
2. Tang, Y., Song, Z., Zhu, Y., Yuan, H., Hou, M., Ji, J., Tang, C., Li, J.: A survey on machine learning models for financial time series forecasting. *Neurocomputing*. 512, 363–380 (2022). <https://doi.org/10.1016/j.neucom.2022.09.003>.

3. Ahmad, R., Kashif, M., Innan, N., Shafique, M.: Quantum vs. Classical Machine Learning: A Benchmark Study for Financial Prediction, <http://arxiv.org/abs/2601.03802>, (2026). <https://doi.org/10.48550/arXiv.2601.03802>.
4. Espín Esparza, E., Jácome Gagnay, R., Vera Pianda, P.: Riesgo y Rendimiento del BVG Index: Análisis y Proyección Econométrica. *Actualidad Económica*. 30, 79–88 (2020).
5. Min, S., Zhang, S.: Stock Market Forecasting Based on Quantum Fuzzy Support Vector Machine. In: *Proceedings of the 2025 International Conference on Digital Management and Information Technology*. pp. 365–371. ACM, Shenyang China (2025). <https://doi.org/10.1145/3736426.3736484>.
6. Murugaraj, G., Krishnan, R., Harikrishnan, L., Sellapan Kandasamy, M.: Systematic Review on the Influence of Classical and Quantum Machine Learning in the Financial Sector. *Data Science and Management*. (2026). <https://doi.org/10.1016/j.dsm.2026.01.001>.
7. Peng, J.: Study on Forecasting Stock Prices Using Machine Learning Techniques: A Comparative Evaluation of Random Forest, Support Vector Machines, and Back Propagation Neural Network. In: *Proceedings of the 2024 International Conference on Digital Economy and Computer Science*. pp. 273–278. ACM, Xiamen China (2024). <https://doi.org/10.1145/3705618.3705665>.
8. Upadhyay, V.P., Panwar, S., Merugu, R., Panchariya, R.: Forecasting Stock Market Movements Using Various Kernel Functions in Support Vector Machine. In: *Proceedings of the International Conference on Advances in Information Communication Technology & Computing - AICTC '16*. pp. 1–5. ACM Press, Bikaner, India (2016). <https://doi.org/10.1145/2979779.2979886>.
9. Sun, Y., Mutalib, S., Omar, Peng: Research on Stock Prediction Model using Mode Decomposition Algorithm and Support Vector Regression. In: *Proceedings of the 2024 Guangdong-Hong Kong-Macao Greater Bay Area International Conference on Digital Economy and Artificial Intelligence*. pp. 378–384. Association for Computing Machinery, New York, NY, USA (2024). <https://doi.org/10.1145/3675417.3675480>.
10. Singh, G., Kaur, M., Singh, M., Kumar, Y.: Implementation of Quantum Support Vector Machine Algorithm Using a Benchmarking Dataset. *Indian Journal of Pure & Applied Physics (IJPAP)*. 60, (2022). <https://doi.org/10.56042/ijpap.v60i5.60456>.
11. Ricky, A., Genesius, K., Setiawan, M., Nugroho Jaya, R., Suhartono, D.: Stock Market Prediction Using Support Vector Regressor with Radial Basis Function Kernel. In: *Proceedings of the 2022 5th International Conference on Image and Graphics Processing*. pp. 380–387. Association for Computing Machinery, New York, NY, USA (2022). <https://doi.org/10.1145/3512388.3512444>.
12. Bhattacharjee, S., Fuad, M.M., Hossain, A.K.M.F.: Classification of Financial Data Using Quantum Support Vector Machine, <http://arxiv.org/abs/2412.10860>, (2024). <https://doi.org/10.48550/arXiv.2412.10860>.
13. Altan, A., Karasu, S.: THE EFFECT OF KERNEL VALUES IN SUPPORT VECTOR MACHINE TO FORECASTING PERFORMANCE OF FINANCIAL TIME SERIES AND COGNITIVE DECISION MAKING. 4, (2019).

14. Kummara, H.V.: Quantum Machine Learning: An Application of Quantum Support Vector Machines for Financial Data Classification, <https://papers.ssrn.com/abstract=5172167>, (2025). <https://doi.org/10.2139/ssrn.5172167>.
15. Rodríguez-Díaz, F., Gutiérrez-Avilés, D., Troncoso, A., Martínez-Álvarez, F.: A Survey of Quantum Machine Learning: Foundations, Algorithms, Frameworks, Data and Applications. *ACM Comput. Surv.* 58, 1–35 (2026). <https://doi.org/10.1145/3764582>.
16. Hidalgo, M.C.: Comparative Analysis of a Quantum SVM With an Optimized Kernel Versus Classical SVMs. *IEEE Access.* 13, 82378–82387 (2025). <https://doi.org/10.1109/ACCESS.2025.3567352>.
17. Herman, D., Googin, C., Liu, X., Galda, A., Safro, I., Sun, Y., Pistoia, M., Alexeev, Y.: A Survey of Quantum Computing for Finance, <http://arxiv.org/abs/2201.02773>, (2022). <https://doi.org/10.48550/arXiv.2201.02773>.
18. S, N., B, G., S, N., H, A.B.: The Potential of Quantum Techniques for Stock Price Prediction, <http://arxiv.org/abs/2308.13642>, (2023). <https://doi.org/10.48550/arXiv.2308.13642>.
19. Suzuki, T., Hasebe, T., Miyazaki, T.: Quantum support vector machines for classification and regression on a trapped-ion quantum computer. *Quantum Mach. Intell.* 6, 31 (2024). <https://doi.org/10.1007/s42484-024-00165-0>.
20. Garrido, R.G.R., Ávila, G.M.C., Naranjo, G.G.M.: Evolución y desarrollo de la bolsa de valores en Ecuador. *Polo del Conocimiento.* 8, 1850–1861 (2023). <https://doi.org/10.23857/pc.v8i1.5169>.
21. Fernández, A., Aguilera, P., Galarza, P.: Análisis del comportamiento bursátil de la corporación favorita en el Ecuador. *593 Digital Publisher CEIT.* 3, 13–20 (2018).
22. Pabuccu, H., Barbu, A.: Feature selection with annealing for forecasting financial time series. *Financ Innov.* 10, 87 (2024). <https://doi.org/10.1186/s40854-024-00617-3>.
23. M, A., S, P.K., R, P., M, T.: Non-Linear Stock Market Prediction with Support Vector Machines. *International Research Journal on Advanced Engineering Hub (IRJAEH).* 3, 615–621 (2025). <https://doi.org/10.47392/IRJAEH.2025.0086>.
24. Meesad, P., Rasel, R.I.: Predicting stock market price using support vector regression. In: 2013 International Conference on Informatics, Electronics and Vision (ICIEV). pp. 1–6. IEEE, Dhaka, Bangladesh (2013). <https://doi.org/10.1109/ICIEV.2013.6572570>.
25. Department of Computer Science and Engineering, Indian Institute of Technology Bombay, India, Patel, A. (Ph. D.C.: ADVANCING FINANCIAL PREDICTION THROUGH QUANTUM MACHINE LEARNING. *ijidml.* 2, 1–7 (2025). <https://doi.org/10.55640/ijidml-v02i02-01>.
26. Girard, T.: Hybrid Quantum-Classical Support Vector Machines for Financial Regime Detection: Performance and Efficiency Evaluation, <https://papers.ssrn.com/abstract=5707104>, (2025). <https://doi.org/10.2139/ssrn.5707104>.

27. Schuld, M., Killoran, N.: Quantum Machine Learning in Feature Hilbert Spaces. *Phys. Rev. Lett.* 122, 040504 (2019). <https://doi.org/10.1103/PhysRevLett.122.040504>.
28. Bustos, O., Pomares-Quimbaya, A.: Stock market movement forecast: A Systematic review. *Expert Systems with Applications*. 156, 113464 (2020). <https://doi.org/10.1016/j.eswa.2020.113464>.
29. Pradasyah, A., Baita, A.: Comparative Study of Support Vector Regression and Long Short-Term Memory for Stock Price Prediction. *Journal of Applied Informatics and Computing*. 9, 1301–1311 (2025). <https://doi.org/10.30871/jaic.v9i4.9425>.
30. Orús, R., Muga, S., Lizaso, E.: Quantum computing for finance: Overview and prospects. *Reviews in Physics*. 4, 100028 (2019). <https://doi.org/10.1016/j.revip.2019.100028>.
31. Mercadier, M.: Quantum-enhanced Versus Classical Support Vector Machine: An Application to Stock Index Forecasting, <https://papers.ssrn.com/abstract=4630419>, (2023). <https://doi.org/10.2139/ssrn.4630419>.